

Decision Trees – חלק 2 – תרגול

חזרה קצרה על מה שנלמד בתרגול הקודם:

- גרדיאנט - וקטור הנגזרות החלקיות
- עבור פונקציה רבת משתנים $f(x_1, x_2, \dots, x_n)$ הגרדיאנט עברה יהיה: $\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$
- הגרדיאנט מצביע לכיוון העלייה התלולה/הגדולה ביותר ביחס לנקודה בה הוא מחושב, וערכו הוא השיפוע בכיוון זה. כך שאם נלך נגד כיוון הגרדיאנט, נתקדם לכיוון המינימום (גרדיאנט דיסנט).
- בנוסף דיברנו על הצורך ב- learning rate, אלפא, במטרה לקבוע כמה מהר או לאט נתקדם לכיוון המינימום (משקל אופטימלי). העלנו את הדיון הבא: מצד אחד לא נרצה אלפא גדולה מידי כדי שלא נגיע למצב בו "דילגנו" על פני המינימום, וכן מצד שני, לא נרצה אלפא קטנה מידי כדי להגיע למינימום בזמן סביר.

תזכורת באלגברה:

- **מפריד לינארי** הוא למעשה היפר-מישור במרחב שמוגדר על ידי הווקטור טטה, וכל הנקודות על ההיפר-מישור הנ"ל פותרות את המשוואה $\theta_1 x_1 + \dots + \theta_n x_n = b$ ($= \theta_0$) כאשר x הן הקואורדינטות של הנקודה.
- ההיפר-מישור מפריד את המרחב לשני חללים, כל הנקודות שהמשוואה פותרת הן מעל b .
- הטטות שולטות בזווית של המישור.
- הטטה מזיזה מראשית הצירים.
- נרצה למצוא מפריד לינארי: כל נקודה עליונה עם תוצאה שגדולה מ-0, תהיה שייכת למחלקה +1 או (-1). כל נקודה תחתונה עם תוצאה נמוכה מ-0, תהיה שייכת למחלקה -1 (או +1).
- לכן עלינו למצוא את הווקטור טטה (שיש בו $n+1$ ערכים, n משקלים וביאס טטה).
- נחזה 1 אם $\sum_{i=1}^n \theta_i x_i + \theta_0 > 0$ ואחרת -1.
- להלן דוגמאות:

• X_1 AND X_2




- Solution?
- If $1 \times X_1 + 1 \times X_2 - 1.5 > 0$ predict 1
- Otherwise predict -1.
- i.e. $\theta_0 = -1.5, \theta_1 = 1, \theta_2 = 1$

• X_1 OR X_2



- Solution?
- $X_1 + X_2 - 0.5 > 0$ predict 1
- Otherwise -1

• X_1 XOR X_2



- Solution?
- There is no solution
- Many functions cannot be represented using a linear separator, i.e., they are not linearly separable


העניין הוא שלא כל דאטה ניתן להפרדה לינארית (להלן בעיית הקסור) ולכן נצטרך כלים קצת יותר חזקים ממפרידים לינאריים (נרחיב עליהם בהמשך).

עצי החלטה

האינטואיציה של עצי החלטה: האטריביוטים שיבחרו, יבחרו על פי מי שמקרב אותנו ביותר להפרדה מלאה בילדים. נרצה למצוא חלוקה לבנים, כך שלאחר החלוקה נהיה כמה שיותר קרובים לטהורות בבנים.

Decision Tree definitions:

- Each internal node (all nodes except the leaves) tests an attribute
- Each branch corresponds to attribute value
- Each leaf node assigns a classification





• עלה הוא תשובה לקלסיפיקציה

• כל ענף מייצג ערך של האטריביוט הנבחר

• כל צומת פנימי בוחנים אטריביוט.

• יודע לטפל גם באטריביוטים רציפים, עבורם נבחר threshold במטרה לחלק לאטריביוטים.



האלגוריתם לבניית העץ: (דוגמה לעץ שנבנה בתור, יש אפשרות לבנות עץ גם ברקורסיה)

- כל עוד יש צמתים בתור תבצע:
- קח את הצומת הבא בתור.
- אם הדגימות בצומת זה טהורים (שייכים כולם לאותו הקלאס) המשך לצומת הבא
- אחרת: נכניס ל-A את האטריביוט הטוב ביותר עבור קבוצת הדגימות בצומת n, נמנה את A לאטריביוט ההחלטה של הצומת n, ולכל ערך של האטריביוט A ניצור בן חדש לצומת n. נפלג את הדגימות של צומת n לבנים החדשים שלו ונכניס את הצמתים הבנים לתור.
- כשאין יותר בנים בתור נסיים את הלולאה

איך בוחרים את **האטריביוט הטוב ביותר** שיקרב אותנו כמה שיותר לטהורות/וודאות? כדי לענות על שאלה זו ראשית עלינו לבחור מדד שיגיד לנו האם הפיצול הוא אכן טוב. עלינו למדוד כמה אנחנו רחוקים מטהורות (perfect classification), **מדידה זו נקראת impurity (מחושב על צומת):**

- Impurity / אי טהורות גבוהה משמעותה – אנחנו רחוקים מקלסיפיקציה מושלמת (ככל שיותר קרובים להתפלגות יוניפורמית נרחק יותר מקלסיפיקציה מושלמת)
- Impurity / אי טהורות נמוכה משמעותה – אנחנו קרובים לקלסיפיקציה מושלמת (בהרצאה מופיעה הגדרה פורמלית יותר)

בחירת האטריביוט הטוב ביותר

- נחשב את רמת הטהורות Impurity עבור הצומת הנוכחי (בו אנו נמצאים)
- נחשב את הממוצע המשוקלל של רמת הטהורות על הצמתים-הבנים לאחר פיצול לפי האטריביוט שנבדק
- נחסיר את השני(הממוצע המשוקלל) מהראשון(רמת הטהורות של האבא) ונקבל את הפרש ה-impurity
- נבחר את האטריביוט שמניב את הפרש ה-Impurity המקסימלי, הגבוהה ביותר
- **הפרש ה-Impurity בין רמת הטהורות של צומת האב לבין ממוצע רמת הטהורות שמתקבלת עבור הבנים לאחר הפיצול נקראת**

Goodness of split

הנוסחה שמחשבת את הפרש ה-Impurity מקבלת שני אינפוטס; את האטריביוט הנבדק A ותת קבוצת הדגימות אשר בצומת הנוכחי:

$$\Delta\varphi(S, A) = \varphi(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \varphi(S_v)$$

* Where φ is the impurity measure

רמת הטהורות בצומת האב פחות הממוצע הממושקל של הטהורות בבנים הנוצרים מהפיצול על פי A (יש לשים לב שהאימפיורטי מחושב על הקלאס ואין שום קשר לערכי האטריביוט כשהוא מגיע לחישוב האימפיורטי מלבד הפיצול לבנים על פי האטריביוט).

עובדות חשובות: (האות היוונית פי מסמלת את ה-impurity)

- מדד אי הטהורות (impurity measure) מודד לפי התפלגות הקלאסים בצומת כלשהו
- הדגימות מפוצלות לפי ערכי האטריביוט הנבדק – A
- זאת אומרת שאנו מפצלים את הדגימות לפי ערכי האטריביוט ואז מחשבים את רמת הטהורות לפי ערכי הקלאסים.

טיב הפיצול / Goodness of Split

ישנם 2 יישומים עיקריים עבור קריטריון הטהורות:


| | Gini | Entropy |
|-------------------|---|--|
| Impurity | $GiniIndex(S) = 1 - \sum_{i=1}^c \left(\frac{ S_i }{ S } \right)^2$ | $Entropy(S) = - \sum_{i=1}^c \frac{ S_i }{ S } \log \frac{ S_i }{ S }$ |
| Goodness of split | $Gini\ Gain =$ $GiniIndex(S) - \sum_{v \in \text{Values}(A)} \frac{ S_v }{ S } GiniIndex(S_v)$ | $Information\ Gain =$ $Entropy(S) - \sum_{v \in \text{Values}(A)} \frac{ S_v }{ S } Entropy(S_v)$ |

- C מסמל את מספר הקלאסים
- הערך המקסימלי שגייני אינדקס יכול לקבל הוא 1, ככל שכמות הקלאסים עולה הסכום שואף ל-0. כאשר יש שני קלאסים המקסימום שגייני יקבל יהיה 0.5
- הערך המקסימלי של אנטרופיה עבור 2 קלאסים הוא 1, עבור 4 קלאסים הוא 2. מה שניתן להבין מכאן הוא שהאנטרופי לא חסום.
- ערכם המינימלי הוא 0.
- את שתי הנוסחאות נמיר לפורמולה של גודנס אוף ספליט ובהן נשתמש (שורה שניה בטבלה).

התמודדות עם אטריביוט עם ערכים רבים

- Imagine using the attribute DAY=[D1,...,D14]

| Day | Outlook | Temperature | Humidity | Wind | PlayTennis |
|-----|----------|-------------|----------|--------|------------|
| D1 | Sunny | Hot | High | Weak | No |
| D2 | Sunny | Hot | High | Strong | No |
| D3 | Overcast | Hot | High | Weak | Yes |
| D4 | Rain | Mild | High | Weak | Yes |
| D5 | Rain | Cool | Normal | Weak | Yes |
| D6 | Rain | Cool | Normal | Strong | No |
| D7 | Overcast | Cool | Normal | Strong | Yes |
| D8 | Sunny | Mild | High | Weak | No |
| D9 | Sunny | Cool | Normal | Weak | Yes |
| D10 | Rain | Mild | Normal | Strong | Yes |
| D11 | Sunny | Mild | Normal | Strong | Yes |
| D12 | Overcast | Mild | High | Strong | Yes |
| D13 | Overcast | Hot | Normal | Weak | Yes |
| D14 | Rain | Mild | High | Strong | No |



$$GainRatio(S, A) = \frac{InformationGain(S, A)}{SplitInformation(S, A)}$$

הדרך להימנע מנטייה זו היא להשתמש ב- **GainRatio**:

ניקח את ה- $InformationGain(S, A)$ ו"ננרמל" אותו על ידי חילוק ב- $SplitInformation(S, A)$.

$$SplitInformation(S, A) = - \sum_{a \in A} \frac{|S_a|}{|S|} \log \frac{|S_a|}{|S|}$$

כאשר $SplitInformation(S, A)$ הוא האנטרופיה ביחס לאטריביוט A:

עד כה חישבנו אנטרופיה עבור קלאס, כעת נחשב אנטרופיה בהתחשב באטריביוט. ככל שיהיו לנו יותר ערכים באטריביוט ככה נגיע למקרה שהוא יותר יוניפורמי. (ככה "מענישים" אטריביוט בעל ערכים רבים)

דוגמה לחישוב ספליט אינפורמיישן וגאין רשיו עבור הדוגמה המוצגת לעיל בתמונה, ועבור האטריביוט Day.


$$SplitInformation(S, Day) = - \sum_{i=1}^{14} \frac{1}{14} \log \frac{1}{14} = -\log \frac{1}{14} = 3.8074$$

$$GainRatio(S, A) = \frac{0.94}{3.8074} = 0.2469$$

אוברפיטניג / Overfitting

בשלב מסוים באלגוריתם הלמידה ככל שהופכים את המודל שלנו למורכב יותר, כך אנחנו מתאימים יותר את המודל שלנו לדאטה שלנו. אנחנו נרצה להגיע למודל כמה שיותר כללי כך שכאשר תגיע דגימה חדשה, המודל ידע להתאים עבורה תוצאה נכונה ביותר.

דוגמה לאוברפיטניג ברגרסיה:




עצי החלטה נוטים ל-overfit. המשמעות של כך היא שהעצים שלנו נעשים יותר ויותר ספציפיים עבור ה-training data. הדרך שלנו להתמודד עם נטייה זו נקראת Pruning.

קיפוצ Pruning

בגישה זו עלינו לקצץ ענפים מהעץ על מנת להפוך אותו לקטן יותר, ובכך נקבל test error טוב יותר.

- אפשר להחליט מראש על גובה עץ מקסימלי לפי ניסוי וטעייה. ננסה גבהים שונים ונחשב עבור כל גובה את ה-validation accuracy הטוב ביותר. (ממש כמו בגרדיאנט דיסנט עם האלפא learning rate)
- אופציה נוספת נקראת post pruning: נעלה במעלה העץ מהעלים לכיוון השורש, עבור כל צומת נחליט האם להשאיר אותו או לקצץ אותו מהעץ. נחליט זאת על בסיס השאלה האם הפיצול לאטריביוט הנ"ל תורם לנו או לא (Chi Square Test).
- אפשר גם לקצץ בזמן בניית העץ = לא ניצור עוד צמתים בנים.



*Chi Square Test:

זוהי בדיקה סטטיסטית שמטרתה להגיד לנו האם הפיצול לפי אטריביוט כלשהו מניבה עבורנו התפלגות שהיא רנדומלית לחלוטין או האם יש לה כוח חיזוי כלשהו. לכן, נבדוק אם פיצול לפי האטריביוט הנבחר מניב עבורנו התפלגות שהיא ממש רנדומלית. אם יש לי בצומת 100 אינסטנסים, אם נחלק אותה רנדומלית, נצפה שהפיצול הרנדומלי יניב בערך את אותו היחס שהיה באבא. האם הילדים שומרים על היחס בין הקלאסים שיש באבא – אם כן, נגזום, לא הרווחנו וודאות! ככל שאנחנו יותר רחוקים ממה שציפינו = החלוקה היא יותר רנדומית. אם אני רחוק מרנדום, נבצע את החלוקה. בדיקה זו מבצעים תוך כדי הבנייה של העץ - בודקים את כוח החיזוי.

הבדיקה מבוצעת באופן הבא:

- The test itself (assume Y can only take values of 0 \ 1):
 - $P(Y = 0) \approx \frac{\# Y=0 \text{ instances}}{\# \text{Instances}}$
 - Call D_f = number of instances where $x_j = f^*$
 - p_f = number of instances where $x_j = f$ & $Y = 0$
 - n_f = number of instances where $x_j = f$ & $Y = 1$
 - $E_0 = D_f * P(Y = 0)$, $E_1 = D_f * P(Y = 1)$
 - So Chi Square statistic is:
- $$\chi^2 = \sum_{f \in \text{values}(x_j)} \frac{(p_f - E_0)^2}{E_0} + \frac{(n_f - E_1)^2}{E_1}$$

עבור כל ילד נחשב ונסכום – כמה דגימות יש לנו בקלאס פחות כמות הדגימות שנצפה לקבל בקלאס0 בריבוע, לחלק לצפי הדגימות בקלאס0. ועוד מספר הדגימות בקלאס1 פחות כמות הדגימות שציפינו שנקבל בקלאס1 בריבוע, לחלק לצפי הדגימות בקלאס1. (החלוקה היא סתם נרמול) המחות היא כמה אני קרוב לצפי שלי. נקבל מספר כלשהו, ונשאל את עצמנו מה זה אומר: בשביל כך יש לנו את טבלת ה-Chi Square.

טבלת ה-Chi Square

מה שמעניין אותנו הם המספרים בתוך הטבלה.

נרצה להבין מה זה אומר Degree of rhythm.

$$\text{DegreeOfRhythm} = (\text{numOfClasses} - 1)(\text{numOfValsInA} - 1)$$

בכל צומת שאנו נמצאים יש כמות אחרת של ערכים לאטריביוט הנבחר. כלומר יתכן שלאטריביוט "תחזית" יש 4 אפשרויות (מעונן, מעונן חלקית, שמש, גשום), אבל בצומת הנוכחי שלנו אין אפשרות ל"תחזית" שמשתית. לכן $\text{numOfValInA} = 3$. מפני שזה מספר הערכים האפשריים של האטריביוט בצומת הנוכחי.

מהו האלפא ריסק Alpha Risk?

אני רוצה להיות רחוק מרנדום

בהסתברות מסויימת (השגיאה שאני

מוכנה לסבול למשל 0.05)

| Table of Probabilities for the Chi-Squared Distribution | | | | | | | | | | | | | | |
|---|----------|----------|----------|---------|--------|--------|--------|---------|---------|---------|---------|---------|---------|---------|
| Alpha Risk | | | | | | | | | | | | | | |
| df | 0.995 | 0.990 | 0.975 | 0.95 | 0.9 | 0.75 | 0.5 | 0.25 | 0.1 | 0.05 | 0.25 | 0.01 | 0.005 | 0.001 |
| 1 | 0.000039 | 0.000157 | 0.000982 | 0.00393 | 0.0158 | 0.102 | 0.455 | 1.323 | 2.706 | 3.841 | 1.323 | 6.635 | 7.879 | 10.828 |
| 2 | 0.010 | 0.020 | 0.051 | 0.103 | 0.211 | 0.575 | 1.386 | 2.773 | 4.605 | 5.991 | 2.773 | 9.210 | 10.597 | 13.816 |
| 3 | 0.072 | 0.115 | 0.216 | 0.352 | 0.584 | 1.213 | 2.366 | 4.108 | 6.251 | 7.815 | 4.108 | 11.345 | 12.838 | 16.266 |
| 4 | 0.207 | 0.297 | 0.484 | 0.711 | 1.064 | 1.923 | 3.357 | 5.385 | 7.779 | 9.488 | 5.385 | 13.277 | 14.860 | 18.467 |
| 5 | 0.412 | 0.554 | 0.831 | 1.145 | 1.610 | 2.675 | 4.351 | 6.626 | 9.236 | 11.070 | 6.626 | 15.086 | 16.750 | 20.515 |
| 6 | 0.676 | 0.872 | 1.237 | 1.635 | 2.204 | 3.455 | 5.348 | 7.841 | 10.645 | 12.592 | 7.841 | 16.812 | 18.548 | 22.458 |
| 7 | 0.989 | 1.239 | 1.690 | 2.167 | 2.833 | 4.255 | 6.346 | 9.037 | 12.017 | 14.067 | 9.037 | 18.475 | 20.278 | 24.322 |
| 8 | 1.344 | 1.646 | 2.180 | 2.733 | 3.490 | 5.071 | 7.344 | 10.219 | 13.362 | 15.507 | 10.219 | 20.090 | 21.955 | 26.124 |
| 9 | 1.735 | 2.088 | 2.700 | 3.325 | 4.168 | 5.899 | 8.343 | 11.389 | 14.684 | 16.919 | 11.389 | 21.666 | 23.589 | 27.877 |
| 10 | 2.156 | 2.558 | 3.247 | 3.940 | 4.865 | 6.737 | 9.342 | 12.549 | 15.987 | 18.307 | 12.549 | 23.209 | 25.188 | 29.588 |
| 11 | 2.603 | 3.053 | 3.816 | 4.575 | 5.578 | 7.584 | 10.341 | 13.701 | 17.275 | 19.675 | 13.701 | 24.725 | 26.757 | 31.264 |
| 12 | 3.074 | 3.571 | 4.404 | 5.226 | 6.304 | 8.438 | 11.340 | 14.845 | 18.549 | 21.026 | 14.845 | 26.217 | 28.300 | 32.909 |
| 13 | 3.565 | 4.107 | 5.009 | 5.892 | 7.042 | 9.299 | 12.340 | 15.984 | 19.812 | 22.362 | 15.984 | 27.688 | 29.819 | 34.528 |
| 14 | 4.075 | 4.660 | 5.629 | 6.571 | 7.790 | 10.165 | 13.339 | 17.117 | 21.064 | 23.685 | 17.117 | 29.141 | 31.319 | 36.123 |
| 15 | 4.601 | 5.229 | 6.262 | 7.261 | 8.547 | 11.037 | 14.339 | 18.245 | 22.307 | 24.996 | 18.245 | 30.578 | 32.801 | 37.697 |
| 16 | 5.142 | 5.812 | 6.908 | 7.962 | 9.312 | 11.912 | 15.338 | 19.369 | 23.542 | 26.296 | 19.369 | 32.000 | 34.267 | 39.252 |
| 17 | 5.697 | 6.408 | 7.564 | 8.672 | 10.085 | 12.792 | 16.338 | 20.489 | 24.769 | 27.587 | 20.489 | 33.409 | 35.718 | 40.790 |
| 18 | 6.265 | 7.015 | 8.231 | 9.390 | 10.865 | 13.675 | 17.338 | 21.605 | 25.989 | 28.869 | 21.605 | 34.805 | 37.156 | 42.312 |
| 19 | 6.844 | 7.633 | 8.907 | 10.117 | 11.651 | 14.562 | 18.338 | 22.718 | 27.204 | 30.144 | 22.718 | 36.191 | 38.582 | 43.820 |
| 20 | 7.434 | 8.260 | 9.591 | 10.851 | 12.443 | 15.452 | 19.337 | 23.828 | 28.412 | 31.410 | 23.828 | 37.566 | 39.997 | 45.315 |
| 21 | 8.034 | 8.897 | 10.283 | 11.591 | 13.240 | 16.344 | 20.337 | 24.935 | 29.615 | 32.671 | 24.935 | 38.932 | 41.401 | 46.797 |
| 22 | 8.643 | 9.542 | 10.982 | 12.338 | 14.041 | 17.240 | 21.337 | 26.039 | 30.813 | 33.924 | 26.039 | 40.289 | 42.796 | 48.268 |
| 23 | 9.260 | 10.196 | 11.689 | 13.091 | 14.848 | 18.137 | 22.337 | 27.141 | 32.007 | 35.172 | 27.141 | 41.638 | 44.181 | 49.728 |
| 24 | 9.886 | 10.856 | 12.401 | 13.848 | 15.659 | 19.037 | 23.337 | 28.241 | 33.196 | 36.415 | 28.241 | 42.980 | 45.559 | 51.179 |
| 25 | 10.520 | 11.524 | 13.120 | 14.611 | 16.473 | 19.939 | 24.337 | 29.339 | 34.382 | 37.652 | 29.339 | 44.314 | 46.928 | 52.620 |
| 26 | 11.160 | 12.198 | 13.844 | 15.379 | 17.292 | 20.843 | 25.336 | 30.435 | 35.563 | 38.885 | 30.435 | 45.642 | 48.290 | 54.052 |
| 27 | 11.808 | 12.879 | 14.573 | 16.151 | 18.114 | 21.749 | 26.336 | 31.528 | 36.741 | 40.113 | 31.528 | 46.963 | 49.645 | 55.476 |
| 28 | 12.461 | 13.565 | 15.308 | 16.928 | 18.939 | 22.657 | 27.336 | 32.620 | 37.916 | 41.337 | 32.620 | 48.278 | 50.993 | 56.892 |
| 29 | 13.121 | 14.256 | 16.047 | 17.708 | 19.768 | 23.567 | 28.336 | 33.711 | 39.087 | 42.557 | 33.711 | 49.588 | 52.336 | 58.301 |
| 30 | 13.787 | 14.953 | 16.791 | 18.493 | 20.599 | 24.478 | 29.336 | 34.800 | 40.256 | 43.773 | 34.800 | 50.892 | 53.672 | 59.703 |
| 40 | 20.707 | 22.164 | 24.433 | 26.509 | 29.051 | 33.660 | 39.335 | 45.616 | 51.805 | 55.758 | 45.616 | 63.691 | 66.766 | 73.402 |
| 50 | 27.991 | 29.707 | 32.357 | 34.764 | 37.689 | 42.942 | 49.335 | 56.334 | 63.167 | 67.505 | 56.334 | 76.154 | 79.490 | 86.661 |
| 60 | 35.534 | 37.485 | 40.482 | 43.188 | 46.459 | 52.294 | 59.335 | 66.981 | 74.397 | 79.082 | 66.981 | 88.379 | 91.952 | 99.607 |
| 70 | 43.275 | 45.442 | 48.758 | 51.739 | 55.329 | 61.698 | 69.334 | 77.577 | 85.527 | 90.531 | 77.577 | 100.425 | 104.215 | 112.317 |
| 80 | 51.172 | 53.540 | 57.153 | 60.391 | 64.278 | 71.145 | 79.334 | 88.130 | 96.578 | 101.879 | 88.130 | 112.329 | 116.321 | 124.839 |
| 90 | 59.196 | 61.754 | 65.647 | 69.126 | 73.291 | 80.625 | 89.334 | 98.650 | 107.565 | 113.145 | 98.650 | 124.116 | 128.299 | 137.208 |
| 100 | 67.328 | 70.065 | 74.222 | 77.929 | 82.358 | 90.133 | 99.334 | 109.141 | 118.498 | 124.342 | 109.141 | 135.807 | 140.169 | 149.449 |

דוגמה לחישוב האנטרופיה ולאחר מכן הכנסה לנוסחת ה-Information Gain:

- What calculations are needed to find the feature to split the root of the decision tree using Information Gain

- Reminder:

$$Information_Gain = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

$$Entropy(S) = - \sum_{i=1}^c \frac{|S_i|}{|S|} \log \frac{|S_i|}{|S|}$$

- c – number of classes
- Values(A) – all the values in the A feature

- We need to calculate:

- Entropy(root)
- Weighted average of the Entropy according to "Attraction"
- Weighted average of the Entropy according to "Weather"

| Instance | Attraction | Weather | Classification |
|----------|------------|---------|----------------|
| 1 | Swim | Hot | - |
| 2 | Dance | Hot | + |
| 3 | Casino | Hot | + |
| 4 | Golf | Hot | - |
| 5 | Swim | Mild | - |
| 6 | Casino | Mild | - |
| 7 | Dance | Mild | + |
| 8 | Golf | Mild | - |
| 9 | Ski | Mild | + |
| 10 | Ski | Cold | + |
| 11 | Casino | Cold | - |
| 12 | Dance | Cold | - |

- Entropy(root)

$$Entropy(root) = - \left(\frac{7}{12} \log \frac{7}{12} + \frac{5}{12} \log \frac{5}{12} \right)$$

- Weighted average of the Entropy according to "Attraction"

$$\sum_{v \in Values(Attraction)} \frac{|S_v|}{|S|} Entropy(S_v)$$

$$= - \left(\frac{2}{12} \left(\frac{2}{2} \log \frac{2}{2} \right) + \frac{3}{12} \left(\frac{2}{3} \log \frac{2}{3} + \frac{1}{3} \log \frac{1}{3} \right) + \frac{3}{12} \left(\frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) + \frac{2}{12} \left(\frac{2}{2} \log \frac{2}{2} \right) + \frac{2}{12} \left(\frac{2}{2} \log \frac{2}{2} \right) \right)$$

- Weighted average of the Entropy according to "Weather"

$$\sum_{v \in Values(Weather)} \frac{|S_v|}{|S|} Entropy(S_v)$$

$$= - \left(\frac{4}{12} \left(\frac{2}{4} \log \frac{2}{4} + \frac{2}{4} \log \frac{2}{4} \right) + \frac{5}{12} \left(\frac{2}{5} \log \frac{2}{5} + \frac{3}{5} \log \frac{3}{5} \right) + \frac{3}{12} \left(\frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) \right)$$

Put it all together in the Information Gain formula

$$Information_Gain(root, Attraction)$$

$$= - \left(\frac{7}{12} \log \frac{7}{12} + \frac{5}{12} \log \frac{5}{12} \right)$$

$$+ \left(\frac{2}{12} \left(\frac{2}{2} \log \frac{2}{2} \right) + \frac{3}{12} \left(\frac{2}{3} \log \frac{2}{3} + \frac{1}{3} \log \frac{1}{3} \right) + \frac{3}{12} \left(\frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) + \frac{2}{12} \left(\frac{2}{2} \log \frac{2}{2} \right) + \frac{2}{12} \left(\frac{2}{2} \log \frac{2}{2} \right) \right) = 0.36$$

Information Gain(root, Weather)

$$= - \left(\frac{7}{12} \log \frac{7}{12} + \frac{5}{12} \log \frac{5}{12} \right)$$

$$+ \left(\frac{4}{12} \left(\frac{2}{4} \log \frac{2}{4} + \frac{2}{4} \log \frac{2}{4} \right) + \frac{5}{12} \left(\frac{2}{5} \log \frac{2}{5} + \frac{3}{5} \log \frac{3}{5} \right) + \frac{3}{12} \left(\frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) \right) = 0.0085$$